

Rapport d'évaluation du Modèle

API d'analyse de sentiments : SocialMetrics AI


Contexte et méthodologie

Ce rapport évalue le service d'analyse de sentiments développé pour SocialMetrics AI, qui est destiné à la surveillance des opinions exprimées sur X. Le système repose sur deux modèles de régression logistique indépendants entraînés sur un même vectoriseur TF-IDF : c'est un modèle qui prédit le caractère positif d'un tweet (colonne positive), l'autre son caractère négatif (colonne négative). Cette approche à deux étiquettes permet de pouvoir gérer les tweets neutres, exclus de l'entraînement lorsqu'ils ne portent aucun sentiment.

Les tweets annotés sont stockés dans une base MySQL (table tweets) et servent de jeu d'entraînement. Le texte est vectorisé via **TfidfVectorizer** (n-grammes de 1 à 3, sublinear_tf activé), puis les modèles sont entraînés avec `class_weight='balanced'` pour compenser le déséquilibre des classes. Les performances rapportées ci-dessous sont mesurées sur un jeu de validation (20 % des données, séparation stratifiée).

Prédictions positives

La matrice de confusion ci-dessous mesure la capacité du modèle à distinguer les tweets positifs (classe 1) des autres (classe 0), sur le jeu de validation.




Classe	Précision	Rappel	F1-score	Support
Classe 0 (non)	60.0%	75.0%	66.7%	4
Classe 1 (oui)	66.7%	50.0%	57.1%	4

Interprétation. Le modèle positif atteint un rappel de 50.0 % sur la classe positive : il ne retrouve qu'une partie des tweets réellement positifs. En revanche sa précision sur cette classe (66.7 %) reste correcte, ce qui signifie que lorsqu'il annonce « positif », il se trompe relativement peu. On observe donc une tendance à **manquer des positifs** (faux négatifs) plutôt qu'à en inventer.

Prédictions négatives

La seconde matrice évalue le modèle chargé de repérer les tweets négatifs (classe 1).



Classe	Précision	Rappel	F1-score	Support
Classe 0 (non)	66.7%	50.0%	57.1%	4
Classe 1 (oui)	60.0%	75.0%	66.7%	4

Interprétation. Le modèle négatif présente le profil inverse du modèle positif : un rappel élevé sur la classe négative (75.0 %) mais une précision plus faible (60.0 %). Il capture donc bien les tweets négatifs, au prix de quelques faux positifs, des tweets classés négatifs à tort.

Analyses de performances

Forces. Les deux modèles produisent des prédictions cohérentes malgré un jeu de données très réduit. La séparation en deux modèles indépendants (positif / négatif) offre une gestion naturelle des tweets neutres et une lecture claire des erreurs par sentiment.

Faiblesses. Les F1-scores se situent autour de 0,57-0,67 selon les classes, ce qui reste modeste. La cause principale est la **taille du corpus** : avec seulement une quarantaine de tweets annotés et un support de 4 exemples par classe en validation, chaque erreur pèse lourd dans les métriques et l'estimation est très instable. Les intervalles de confiance réels autour de ces chiffres sont larges.

Biais observés. Les deux modèles sont symétriquement asymétriques : le modèle positif privilégie la précision au détriment du rappel (il rate des positifs), tandis que le modèle négatif privilégie le rappel au détriment de la précision (il sur-détecte le négatif). Sur un flux réel où les tweets neutres dominent, ce second biais tendrait à surestimer la négativité globale. Le vectoriseur TF-IDF ne capture par ailleurs ni l'ironie, ni la négation (« pas mal », « ce n'est pas génial »), sources classiques d'erreurs.

Recommandations

- **Augmenter le volume de données annotées** : c'est le levier le plus déterminant. Passer de quelques dizaines à plusieurs centaines ou milliers de tweets réduirait drastiquement la variance des métriques et fiabiliserait l'évaluation.
- **Valider par validation croisée** (k-fold) plutôt qu'un simple split 80/20, afin d'obtenir des scores stables et une vraie mesure de généralisation sur un si petit corpus.
- **Enrichir le prétraitement** : gestion explicite de la négation, normalisation des émojis et de la ponctuation expressive, lemmatisation française, pour mieux capter le sentiment.
- **Ajuster les seuils de décision** par modèle selon l'objectif métier (rééquilibrer précision et rappel), et suivre l'évolution des métriques au fil des réentraînements hebdomadaires.
- **Envisager des modèles plus riches** à mesure que le corpus grandit (embeddings, modèles pré-entraînés type CamemBERT) pour dépasser les limites du TF-IDF + régression logistique.

*Note méthodologique : le réentraînement est automatisé chaque semaine (cronjob) sur les données les plus récentes de la table **tweets**, régénérant modèles, matrices de confusion et métriques. Les chiffres de ce rapport reflètent le dernier entraînement en date.*